

第一章 程序

1.1 原理介绍

Vision Transformer(ViT) 由 Dosovitskiy 等人^[1]提出,Transformer 是自然语言处理(Natural Language Processing, NLP)中常见的模型,而在计算机视觉(Computer Vision, CV)领域,注意力机制的应用范围仍然较小,通常是替换卷积神经网络(Convolutional Neural Network, CNN)中的一部分组件,同时保持其整体结构不变。作者等人发现对 CNN 的依赖是毫无必要的,在图像分类任务上单纯使用 Transformer 能够带来更好的效果。




图 1.1: 模型结构

模型结构如 1.1所示,首先目标图片被划分为几个大小相同的 patch,线性组合后输入到一个标准的 Transformer Encoder 中,在输入到一个多层感知器(Multi-Layer Perceptron, MLP)中得到分类的结果。

本实验中,ViT 的实现依赖了开源项目 vit-pytorch^[2]。

第一章 程序 2

1.2 实现细节

如图 1.2所示是 ViT 模型中 __init__ 方法的代码, 定义了模型的结构, 与 1.1所示结构一致。

图 1.2: __init__ 代码

如图 1.3所示是 ViT 模型中 forward 方法的代码,描述了模型正向传播的过程。

如图 1.4所示是训练一个 epoch 的代码。

第一章 程序 3

图 1.3: forward 代码

图 1.4: train_epoch 代码

第二章 结果

经过 25 个 epoch 的训练后效果如图 2.1所示。 train loss 如图 2.2所示。 test loss 如图 2.3所示。

图 2.1: result

第二章 结果 5




图 2.2: train loss




图 2.3: test loss

参考文献

- [1] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[C]//International Conference on Learning Representations. 2021.
- [2] LUCIDRAINS. vit-pytorch[EB/OL]. 2020. https://github.com/lucidrains/vit-pytorch.